

Sistemas de Recuperación de Información y de Recomendación

Máster en Ciencia de Datos e Ingeniería de Computadores

Desarrollo de un Sistema RAG para Recomendación Basada en Contenido

Dataset: Amazon Reviews 2023 — Digital Music

0 Índice

1. Introducción	2
2. Conjunto de Datos	2
3. Módulo I: Procesado de Ítems	3
3.1. Estrategia de preprocesado	3
3.2. Enriquecimiento con reseñas de usuarios	3
3.3. Estructura del documento-ítem	3
4. Módulo II: Indexación y Recuperación	4
4.1. Modelo de embeddings	4
4.2. Normalización L2 e índice FAISS	4
4.3. Construcción de perfiles de usuario	4
4.4. Recuperación matricial	4
5. Módulo III: Aumentación	5
6. Módulo IV: Generación	5
7. Módulo V: Filtro de Alucinaciones	6
8. Resultados Cualitativos	6
8.1. Análisis por perfil	6
8.2. Evaluación de la salida	6
9. Módulo VI: Evaluación	7
9.1. Protocolo de evaluación	7
9.2. Resultados cuantitativos	7
9.3. Análisis e interpretación	7
10. Conclusiones	8
Bibliografía	8

1 Introducción

Un sistema de Generación Aumentada por Recuperación (*Retrieval-Augmented Generation*, RAG) es una arquitectura híbrida que combina un motor de recuperación de información con un LLM. En lugar de confiar únicamente en el conocimiento adquirido durante el preentrenamiento, el sistema primero consulta una base de conocimiento externa para obtener fragmentos relevantes al contexto de la consulta, y luego el LLM los emplea para generar una respuesta más precisa e informada.

En el contexto de los sistemas de recomendación basados en contenido (SRC), esta arquitectura resulta especialmente adecuada por varias razones: permite trabajar con catálogos de gran tamaño sin reentrenar el modelo, reduce las alucinaciones al proporcionar contexto real al LLM, y habilita recomendaciones explicables, ya que la justificación puede fundamentarse en los metadatos y reseñas recuperados.

El objetivo principal de esta práctica es diseñar, implementar y evaluar un SRC mediante una arquitectura RAG, integrando técnicas de Recuperación de Información (IR), concretamente recuperación semántica vectorial, con LLMs de código abierto para proporcionar recomendaciones personalizadas y explicables en el dominio de la música digital. El sistema sigue el flujo ilustrado en la Figura 1: los ítems del catálogo se procesan, se vectorizan y se almacenan en una base de datos vectorial. Ante la llegada de un perfil de usuario (que actúa como consulta), el sistema recupera los ítems más similares semánticamente, construye un *prompt* aumentado y lo envía a un LLM para obtener una recomendación final ordenada y justificada.




Figura 1: Arquitectura RAG implementada.

2 Conjunto de Datos

Se ha seleccionado la subcategoría **Digital Music** del *dataset* Amazon Reviews 2023 [3], una colección ampliamente utilizada en investigación de sistemas de recomendación que proporciona tanto reseñas de usuarios como metadatos estructurados de los productos. Su elección se justifica por dos razones principales: la presencia de texto rico en ambos ficheros (metadatos descriptivos y reseñas narrativas) y la orientación explícita hacia la recomendación basada en contenido, a diferencia de colecciones diseñadas para filtrado colaborativo.

El *dataset* se distribuye en dos ficheros JSONL independientes cuyos campos principales se recogen en la Tabla 1.

Cuadro 1: Campos del conjunto de datos Amazon Digital Music 2023.

Fichero	Registros	Campos clave
Digital_Music.jsonl (reseñas)	130 434	rating, title, text, user_id, parent_asin
meta_Digital_Music.jsonl (metadatos)	70 537	title, store, categories, features, description, details, parent_asin

El campo de unión entre ambos ficheros es `parent_asin`. Se observó además que `description` y `categories` son frecuentemente listas vacías, y que el campo `bought_together` presenta un 100 % de valores nulos, por lo que fue descartado. El campo `store` contiene habitualmente el nombre del artista o sello discográfico y resultó ser uno de los más informativos junto con el título.

3 Módulo I: Procesado de Ítems

3.1 Estrategia de preprocesado

El preprocesado de ítems constituye el primer módulo del sistema y tiene como objetivo transformar la información heterogénea de cada producto en un único documento textual normalizado, denominado en adelante *documento-ítem*.

El proceso sigue los siguientes pasos para cada campo textual:

1. **Eliminación de HTML:** se emplea `BeautifulSoup` para extraer el texto plano eliminando cualquier etiqueta HTML presente, especialmente frecuente en el campo `description`.
2. **Eliminación de caracteres de control:** saltos de línea, tabuladores y retornos de carro se sustituyen por espacios.
3. **Filtrado de caracteres especiales:** se conservan letras, números y puntuación básica, descartando el resto mediante una expresión regular.
4. **Conversión a minúsculas.**
5. **Colapso de espacios múltiples:** el resultado se normaliza a un único espacio entre tokens.

3.2 Enriquecimiento con reseñas de usuarios

Dado que los campos `description`, `features` y `categories` de los metadatos están vacíos en una fracción significativa de los ítems, se tomó la decisión de enriquecer cada documento-ítem concatenando el texto de hasta cinco reseñas de usuarios (título y cuerpo de la reseña). Esta estrategia permite que incluso los ítems con metadatos escasos dispongan de una semántica suficiente para la vectorización. El campo de texto agregado se añade bajo la etiqueta `user reviews`.

3.3 Estructura del documento-ítem

La concatenación de todos los campos se realiza con el separador `|` para delimitar semánticamente los metadatos. El orden de los campos, de mayor a menor relevancia esperada, es:

title → artist → genres → features → description → details → average rating →
user reviews

Todos los ítems del catálogo dispusieron de al menos un campo textual, por lo que el corpus final no descartó ningún registro, obteniéndose **70 537 documentos-ítem** con una longitud media de **702 caracteres** y un mínimo de 102 caracteres.

4 Módulo II: Indexación y Recuperación

4.1 Modelo de embeddings

Para la vectorización de los documentos-ítem se utilizó el modelo **all-MiniLM-L6-v2** de la biblioteca **sentence-transformers** [4]. La elección se justifica por su equilibrio entre calidad semántica y eficiencia computacional: genera vectores densos de **384 dimensiones** y puede ejecutarse íntegramente en CPU, aunque en este proyecto se aprovechó la GPU T4 disponible en Google Colab para acelerar el proceso.

La codificación de los 70 537 documentos se realizó en lotes de 512 ítems para evitar saturar la memoria de la GPU, resultando en una matriz de embeddings de dimensión $70\,537 \times 384$.

4.2 Normalización L2 e índice FAISS

Con el objetivo de simular la similitud del coseno mediante un producto escalar, todos los vectores fueron normalizados mediante `faiss.normalize_L2()`. El índice utilizado es `faiss.IndexFlatIP` [5], tal y como propone el guion.

4.3 Construcción de perfiles de usuario

En la terminología RAG, los perfiles de usuario actúan como consultas al sistema de recuperación. Se construyeron **seis perfiles** con dos estrategias complementarias:

Perfiles reales (3): se identificaron los usuarios más activos del *dataset* y se construyó su perfil concatenando los documentos-ítem de sus productos mejor valorados ($\text{rating} \geq 4,0$), hasta un máximo de 10 ítems. Los tres usuarios seleccionados se caracterizan respectivamente por preferencias en música clásica, coleccionismo de álbumes de los Beatles, y piano.

Perfiles sintéticos (3): se redactaron manualmente prompts descriptivos con preferencias musicales genéricas pero dispares. Los perfiles diseñados fueron:

- **user_synth_classical**: aficionado a música clásica barroca y romántica (Bach, Beethoven, Mozart, Chopin), con preferencia por sonatas para piano, sinfonías y cuartetos de cuerda.
- **user_synth_hiphop**: fanático del hip-hop y rap de los años 90 y 2000 (Tupac, Notorious B.I.G., Jay-Z, Kendrick Lamar), con interés en el boom bap y letras de contenido social.
- **user_synth_jazz**: apasionado del jazz en todas sus formas (bebop, cool jazz, fusión, jazz latino) con artistas favoritos como Miles Davis, John Coltrane y Bill Evans.

4.4 Recuperación matricial

La recuperación se realizó mediante una única llamada a FAISS con todos los perfiles agrupados. Se recuperaron hasta 20 candidatos por perfil. La Tabla 2 muestra los cinco primeros ítems recuperados para cada perfil sintético, evidenciando la coherencia semántica de los resultados.

Cuadro 2: Top-5 ítems recuperados por FAISS para los tres perfiles sintéticos.

Rank	Classical	Hip-Hop	Jazz
1	Collector's Classics Vol. 2	Control System	17 Classic Albums (Miles Davis)
2	Classical Music for People...	I Like It Like That	Making Choices: Evolutions in Jazz
3	The Classical Music for Reading	Hated By Many	Jazz with Prestige
4	Classics for Relaxation	Mostly People	In the Mood for Jazz
5	100 Masterpieces of Classical Music	Hip Hop 2 The Absolute Best	Miles Davis: His Favorite Tenors

5 Módulo III: Aumentación

El módulo de aumentación construye el *prompt* que se envía al LLM combinando el perfil del usuario con los candidatos recuperados. La estructura del *prompt* diseñado sigue fielmente las indicaciones del guion e incluye los siguientes bloques:

1. **Rol:** define al LLM como sistema de recomendación musical, estableciendo el contexto de la tarea.
2. **Perfil del usuario:** texto del perfil (truncado a 600 caracteres para no saturar el contexto).
3. **Candidatos recuperados:** los 10 primeros ítems del ranking FAISS, con título, ASIN, puntuación de similitud y los primeros 300 caracteres del documento-ítem.
4. **Instrucciones de generación:** cuatro directrices del guion que el modelo debe seguir: RE-RANKING, JUSTIFICACIÓN, FILTRO DE CALIDAD e INTEGRIDAD.
5. **Formato de salida:** especificación JSON estricta con los campos `ranking`, `title`, `asin` y `reasoning`.

Cabe destacar la instrucción de INTEGRIDAD, dado que prohíbe al LLM sugerir ítems que no aparezcan en la lista de candidatos, lo que constituye el principal mecanismo de prevención de alucinaciones a nivel de *prompt*. La decisión de limitar a 10 candidatos (de los 20 recuperados) responde al objetivo de mantener el *prompt* dentro de límites razonables de longitud sin sacrificar diversidad de elección.

6 Módulo IV: Generación

Para la fase de generación se utilizó **Gemini 3 Flash** a través de *Google AI Studio*. La elección se justifica por su accesibilidad sin coste para proyectos académicos y su capacidad para seguir instrucciones de formato complejas.

El modelo recibe el *prompt* aumentado y devuelve una lista JSON con los tres ítems reordenados y justificados. La función implementada permite hasta tres reintentos ante fallos de red, y valida que la respuesta sea una lista JSON bien formada antes de procesarla.

Se pasaron a Gemini los 10 mejores candidatos de FAISS y se le pidió que seleccionara y reordenara los 3 mejores, añadiendo una justificación breve para cada uno. Este enfoque de *re-ranking* mediante LLM aprovecha la capacidad del modelo para razonar sobre la coherencia entre el perfil del usuario y el contenido de cada ítem a un nivel semántico más preciso que el embedding.

7 Módulo V: Filtro de Alucinaciones

El filtro de alucinaciones verifica que cada ítem devuelto por el LLM en el JSON de salida corresponda a un candidato que estaba efectivamente en la lista de entrada. La verificación se realiza por dos vías: coincidencia de ASIN y de título; de forma que un ítem se marca como alucinación si ninguna de las dos verificaciones tiene éxito.

Los resultados sobre los seis perfiles fueron contundentes: **0 alucinaciones en los 18 ítems evaluados** (tasa del 0 %). Este resultado valida la efectividad de la instrucción INTEGRIDAD incorporada al *prompt*, que explícitamente prohíbe al modelo inventar ítems fuera de los candidatos proporcionados. La doble verificación por ASIN y título actúa además como red de seguridad ante posibles variaciones menores en el texto generado.

8 Resultados Cualitativos

8.1 Análisis por perfil

La Tabla 3 recoge las recomendaciones finales generadas por Gemini para cada perfil, indicando el re-ranking respecto al orden original de FAISS.

Cuadro 3: Recomendaciones finales del LLM y re-ranking respecto a FAISS.

Perfil	Primer ítem recomendado	Alucin.	Re-ranks	Válidos
Real #1	Laborintus II	0	1	3
Real #2	Not a Second Time	0	2	3
Real #3	Debussy Das Gesamtwerk	0	2	3
Sintético (Classical)	The Classical Music for Reading	0	3	3
Sintético (Hip-Hop)	Control System (Ab-Soul)	0	2	3
Sintético (Jazz)	17 Classic Albums (Miles Davis)	0	2	3
Total		0	12	18

8.2 Evaluación de la salida

En resumen, la calidad de la salida del sistema RAG puede considerarse **alta** tanto en coherencia como en explicabilidad. En todos los casos, los tres ítems recomendados guardan una relación semántica clara con el perfil del usuario, y las justificaciones generadas por Gemini son específicas y fundamentadas en las características reales de cada ítem.

Cabe mencionar además, el comportamiento del perfil sintético de jazz, donde el LLM promovió *Portrait in Jazz* de Bill Evans desde la posición 8 de FAISS hasta la posición 3 en su re-ranking, argumentando explícitamente que Bill Evans es uno de los artistas favoritos mencionados en el perfil y que el álbum ejemplifica las armonías complejas y la improvisación que el usuario busca. Este tipo de razonamiento preciso sobre el contenido del perfil no es alcanzable mediante similitud vectorial pura, lo que demuestra el valor añadido de la fase de generación. Asimismo, para el perfil clásico sintético, el LLM reordenó los tres candidatos respecto a FAISS, ascendiendo colecciones que mencionaban explícitamente a Bach, Beethoven o piano frente a otras más genéricas recuperadas por similitud global.

En conjunto, la tasa de re-ranking del 66,7 % (12 de 18 ítems cambiaron de posición) y la tasa de alucinaciones del 0 % reflejan un sistema que añade valor real sobre la recuperación vectorial sin introducir ruido.

9 Módulo VI: Evaluación

9.1 Protocolo de evaluación

La evaluación formal del módulo de recuperación se realizó mediante la estrategia *leave-one-out* sobre usuarios reales del *dataset*. Para cada usuario con al menos tres reseñas positivas ($\text{rating} \geq 4,0$), se construyó su perfil con los primeros $n - 1$ ítems y se utilizó el último como *ground truth*. Sobre 300 usuarios seleccionados se calcularon las métricas de recuperación estándar en IR: Precision@K , Recall@K , NDCG@K y MRR , para $K \in \{5, 10, 20\}$.

9.2 Resultados cuantitativos

Los resultados se recogen en la Tabla 4 y se ilustran en la Figura 2.

Cuadro 4: Métricas de evaluación del sistema de recuperación FAISS (300 usuarios).

Métrica	$K = 5$	$K = 10$	$K = 20$
Precision@K	0.0127	0.0083	0.0048
Recall@K	0.0633	0.0833	0.0967
NDCG@K	0.0330	0.0394	0.0426
MRR		0.0263	
Hit Rate@20		0.0967	




Figura 2: Distribución de posición del ítem relevante, métricas por K y Hit Rate acumulado.

9.3 Análisis e interpretación

Los valores numéricos obtenidos son bajos en términos absolutos, pero esto es **esperable y no implica un fallo del sistema**. El escenario de evaluación es extremadamente exigente: existe un único ítem relevante por usuario en un espacio de búsqueda de 70 537 candidatos, y el perfil se construye con ítems del mismo usuario pero distintos a los del *ground truth*. En este contexto, un Hit Rate@20 del 9,67 % significa que en casi 1 de cada 10 usuarios el sistema sitúa el ítem relevante entre los 20 primeros, lo cual es un resultado razonable para recuperación puramente basada en contenido sin información colaborativa.

La curva de Hit Rate acumulado (Figura 2, derecha) muestra una saturación temprana, es decir, la mayoría de los hits se producen en los primeros $K = 10$ posiciones, lo que indica que cuando el sistema acierta, tiende a situar el ítem relevante en puestos altos del ranking. Esto se confirma también con la posición media del ítem relevante de **6.1** entre los usuarios con hit, un valor que refleja buena calidad de ordenación local.

La $\text{Precision@}K$ decrece con K (comportamiento esperado en IR) dado que el denominador crece más rápido que los aciertos adicionales. Por otro lado, el $\text{NDCG@}K$ crece suavemente con K porque los hits que aparecen en posiciones elevadas penalizan menos al índice. Y el MRR de 0.0263 equivale a una posición armónica media del ítem relevante de aproximadamente 38, considerando el total de usuarios.

Las limitaciones de rendimiento observadas se atribuyen principalmente a tres factores: (1) la escasez de señal textual en muchos de los ítems, cuyo documento-ítem está dominado por reseñas en lugar de descripciones; (2) la capacidad limitada de `all-MiniLM-L6-v2` para capturar relaciones entre artistas o géneros musicales de larga cola; y (3) la naturaleza del propio *dataset*, donde muchos usuarios tienen un historial muy reducido que dificulta la construcción de un perfil representativo.

10 Conclusiones

En esta práctica se ha implementado un sistema RAG completo para recomendación musical basada en contenido sobre el *dataset* Amazon Digital Music 2023. Los seis módulos del sistema han funcionado correctamente de forma integrada:

El módulo de procesamiento transformó los 70 537 ítems en documentos-ítem estructurados y enriquecidos con reseñas de usuarios, subsanando la escasez de descripciones en los metadatos originales. La vectorización con `all-MiniLM-L6-v2` y la indexación con FAISS permitieron construir un motor de búsqueda semántica eficiente. Además, la búsqueda matricial demostró ser una alternativa escalable y eficiente a la iteración individual sobre los perfiles.

La fase de generación con Gemini 3 Flash añadió un valor cuantificable sobre la recuperación pura, con un 66,7 % de los ítems re-ranqueados respecto al orden original (FAISS), con justificaciones fundamentadas en el contenido de cada ítem. El filtro de alucinaciones registró una tasa del 0 %, validando la efectividad del diseño del *prompt*. Y la evaluación formal mediante *leave-one-out* ofreció métricas coherentes con las expectativas para un sistema de recuperación basado en contenido sobre un catálogo de gran tamaño.

Como mejoras futuras, se podrían explorar modelos de *embedding* más potentes (o específicos del dominio musical), e incorporar enfoques colaborativos para enriquecer los perfiles de usuario.

10 Bibliografía

10 Referencias

- [1] Lewis, P., et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. Proceedings of NeurIPS 2020. <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>
- [2] Zhao, P., et al. (2025). *Retrieval-Augmented Generation for AI-Generated Content: A Survey*. Data Science and Engineering. <https://link.springer.com/article/10.1007/s41019-025-00335-5>
- [3] Hou, Y., et al. (2024). *Bridging Language and Items for Retrieval and Recommendation*. arXiv:2403.03952. <https://amazon-reviews-2023.github.io>
- [4] Reimers, N. & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. Proceedings of EMNLP 2019. <https://www.sbert.net>
- [5] Johnson, J., Douze, M. & Jégou, H. (2021). *Billion-scale similarity search with GPUs*. IEEE Transactions on Big Data. <https://github.com/facebookresearch/faiss>

- [6] Google DeepMind (2024). *Gemini: A Family of Highly Capable Multimodal Models*. <https://deepmind.google/technologies/gemini/>